Занятие 4

↙ здесь

Субградиентный метод + адаптивные методы.

$\min_{x \in \mathbb{R}^d} f(x)$

f – L-гладкая.

$\| \nabla f(y) - \nabla f(x) \| \le L \|y - x\|$

$\forall x, y \in \mathbb{R}^d$

$\not\Leftarrow$ $f(x) = |x|$

$y = \delta, \quad x = -\delta, \quad \delta > 0$

$|f'(\delta) - f'(-\delta)| \le L \cdot 2\delta$

$\| \cdot \|$ $\Updownarrow$ $\| \cdot \|$

$2 \le 2L\delta \quad \forall \delta > 0$

$\delta \to 0 \Rightarrow L = \infty \Rightarrow f(x)$ не является L-гладкой

- f – M-липшицева: $\forall x, y \in \mathbb{R}^d \Rightarrow$ Assumptions.

  $\Rightarrow |f(y) - f(x)| \le M \|y - x\|$

- f может расти только как „линия"

  $f(x) = \langle a, x \rangle + b, \quad f(x) = \|Ax\|_p$

- $f(x)$ – M-липшицева $\Rightarrow$ $f(x)$ не может быть μ-сильно выпуклой.

- f – выпуклая.

GD: $x_{k+1} = x_k - \gamma \nabla f(x_k)$ ✗

Опр $g \in \mathbb{R}^d$ – субградиент f в $(\cdot) x$, если

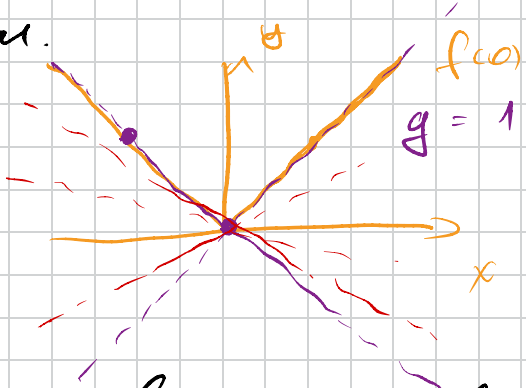
$\forall y \in \mathbb{R}^d \quad f(y) \geq f(x) + \langle g, y - x \rangle$

[$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$]

Опр $\partial f(x) = \{ g \in \mathbb{R}^d \mid g$ – субград f в $(\cdot) x \}$

– субдифференциал.

$f(x) = |x|$



g – аналог градиента в каком-то виде.

Св-ва.

1) Условие оптимальности. ($\nabla f(x) = 0$)

$0 \in \partial f(x) \Leftrightarrow x$ – оптимальная точка.

• Если f – невыпукла $\Rightarrow$ могут существовать $(\cdot) x$: $\partial f(x) = \emptyset$

2) f – выпукла. Тогда

f: M – минимумов $\Leftrightarrow \forall x \in \mathbb{R}^d \; \forall g \in \partial f(x)$

$\|g\| \le M$

$\Rightarrow$

$\forall x \; \forall g \in \partial f(x) \Rightarrow \forall y \in \mathbb{R}^d \quad f(y) \ge f(x) + \langle g, y-x \rangle$

$\langle g, y-x \rangle \le f(y) - f(x) \le |f(y) - f(x)| \le$

$\le M \|y-x\|$

$\forall y = x + g \Rightarrow \|g\|_2^2 \le M \|g\|_2$

Если $\|g\| = 0 \Rightarrow \|g\| \le M$

Если $g \neq 0 \Rightarrow \|g\| \le M$ ч.т.д.

$\Leftarrow$

$\forall x \quad \forall g \in \partial f(x) \Rightarrow \forall y \in \mathbb{R}^d \quad f(y) \ge f(x) + \langle g, y-x \rangle$

$\Rightarrow \langle g, x-y \rangle \ge f(x) - f(y)$

КБШ $\Rightarrow \|g\|_2 \|x-y\|_2 \ge f(x) - f(y)$

$\Rightarrow M \|x-y\|_2 \ge f(x) - f(y)$

по симметрии: $M \|y-x\|_2 \ge f(y) - f(x)$

$\Rightarrow M \|y-x\| \ge |f(y) - f(x)|$ ч.т.д.

Субградиентный метод.

$\left[x_{k+1} = x_k - \gamma g_k; \quad g_k \in \partial f(x_k) \right]$ (0)

1) Транспортные задачи. ($f(x) = \|Ax\|_1$)

2) Специфические задачи с аргументом: matrix.

$f(X) = \lambda_{max}(X)$

$f(x)$ – не дифф в X: кратность

$\lambda_{max}(X) \geq 1$

GD: $\gamma^2 \|\partial f(x_k)\|^2 \leq 2\gamma^2 L \cdot (f(x_k) - f^*)$

① ②

Proof.

$\|x_{k+1} - x^*\|^2 = \|x_k - x^*\|^2 - 2\gamma \langle g_k, x_k - x^* \rangle + \gamma^2 \|g_k\|^2$

① $f(x^*) \geq f(x_k) - \langle g_k, x_k - x^* \rangle \Rightarrow$

$\Rightarrow -\langle g_k, x_k - x^* \rangle \leq -(f(x_k) - f^*)$ ✓

② $\|g_k\|^2 \leq M^2$

$\sum_{k=0}^{K-1} \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 = \|x_0 - x^*\|^2 - \|x_K - x^*\|^2$

$\|x_{k+1} - x^*\|^2 \leq \|x_k - x^*\|^2 - 2\gamma(f(x_k) - f^*) + \gamma^2 M^2$

$\sum_{k=0}^{K-1} 2\gamma (f(x_k) - f^*) \leq \|x_0 - x^*\|^2 - \|x_K - x^*\|^2 + K\gamma^2 M^2$

$\leq \|x_0 - x^*\|^2 + K\gamma^2 M^2$

$\left| : 2\gamma K \right.$

$\frac{1}{K} \sum_{k=0}^{K-1} (f(x_k) - f^*) \leq \underbrace{\frac{R_0^2}{2\gamma K} + \frac{\gamma M^2}{2}}_{(*)} = \varphi(\gamma)$???

$R_0 = \|x_0 - x^*\|$

// Jensen's ineq

$$f\left(\frac{1}{K}\sum_{k=0}^{K-1} x_k\right) \to f$$

1) $\gamma = \arg\min_{\gamma \geq 0} \varphi(\gamma)$

2) Equilibrium: $\frac{R_0^2}{\gamma K} = \gamma M^2 \Rightarrow$

$$\Rightarrow \boxed{\gamma = \frac{R_0}{M\sqrt{K}}} \Rightarrow$$

$$\Rightarrow (*) = \frac{MR_0}{\sqrt{K}} \Rightarrow$$

$$\Rightarrow crit(K) = O\left(\frac{MR_0}{\sqrt{K}}\right)$$

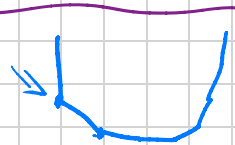
Св-ва

1) Скорость: сублинейная ($\frac{1}{\sqrt{K}}$ против $\frac{1}{K}$ у GD)

2) $$\boxed{\gamma = \frac{R_0}{M\sqrt{K}}}$$

GD: $\gamma \sim \frac{1}{L}$

$L - ?$ 1!!!



$\|x_0 - x^*\|$ (3), M (2), K (1)

1) $\gamma = \frac{R_0}{M\sqrt{K}} \to \gamma_k = \frac{R_0}{M\sqrt{k+1}}$ ✓

1) + 2) $\|g_k\| \sim M$? $\|g_k\| = M_k$ ✓

$$\frac{R_0}{M\sqrt{k}} \to \frac{R_0}{\sqrt{\sum_{t=0}^{k} \|g_t\|^2}} \sim \frac{R_0}{M\sqrt{k+1}}$$

↓ k+1 слагаемое $\sim M$

$$\frac{R_0}{\sqrt{b_{-1}^2 + \sum_{t=0}^{k} \|g_t\|^2}} = \gamma_k$$ ← новый шаг в субградиентном методе.

① AdaGrad-Norm. 2010 (Strehtir), 2011 (Duchi)

$$x_{k+1} = x_k - \frac{R_0}{\sqrt{b_{-1}^2 + \sum_{t=0}^{k} \|g_t\|^2}} g_t$$

↓ ← статистика на основе нормы.

$$\begin{cases} b_k^2 = b_{k-1}^2 + \|g_k\|^2 \\ x_{k+1} = x_k - \frac{R_0}{b_k} g_k \end{cases}$$

② AdaGrad.

$$\begin{cases} b_{k,i}^2 = b_{k-1,i}^2 + (g_{k,i})^2 \\ x_{k+1,i} = x_{k,i} - \frac{R_0}{b_{k,i}} g_{k,i} \end{cases}$$

③ 2012 (Tieleman)

RMSProp – Norm

$$\begin{cases} v_k^2 = \beta_2 v_{k-1}^2 + (1-\beta_2)\|g_k\|^2 \\ x_{k+1} = x_k - \dfrac{D}{v_k} g_k \end{cases}$$

аналог. (R_0)

$\beta_2 \in (0,1)$

экспоненциальное сглаживание.

---

④ 2014, Kingma. Adam-Norm.

$$\begin{cases} m_k = \beta_1 m_{k-1} + (1-\beta_1) g_k; \quad m_{-1} = 0 \quad (1) \\ v_k^2 = \beta_2 v_{k-1}^2 + (1-\beta_2)\|g_k\|^2 \\ x_{k+1} = x_k - \dfrac{D/R_0}{v_k} m_k \end{cases}$$

! $\beta_2 \approx 1 - \frac{1}{K}$!

(1) $\equiv$ HB.

↖ с точностью до константы перед направлением g_k.

- 2016 (Dozat) — NAdam.
- ICLR 2018, best paper! AmsGrad. Reddi.

1) $v_k^2 = \max\left(v_{k-1}^2, \beta_2 v_{k-1}^2 + (1-\beta_2)\|\nabla f(x_k)\|^2\right)$

2) !!! $\beta_1 < \sqrt{\beta_2} \Rightarrow \exists f(x,\xi)$ [∇_x стохастической оптимизации): Adam расходится.

$\beta_1 = 0{,}9$; $\beta_2 = 0{,}999$

- AdamW (по-новому 2017)

(Loshchilov) и decoupled

Adam – done.

$$x_{k+1} = x_k - \frac{\Delta}{\sigma_k} m_k - \lambda_k x_k =$$

$$= (1 - \lambda_k) x_k - \frac{\Delta}{\sigma_k} m_k$$

← weight decay

На каждой итерации:

$$\min_{x \in \mathbb{R}^d} \left(f(x) + \frac{\lambda_k}{2} \|x\|_2^2 \right)$$

Adam ⊕ GD.

В сопех → strongly convex.

В полсопех → ничего не меняется :)

- 2025 год: Secret Sauce of Adam.

$\beta_1 = \beta_2$! Теория из статистического вывода

---

3) R_0 – ? Parameter-free подходы.

D-Adaptation (best paper 2022)

Diminishing steps

$\sum_{k=1}^{\infty} \gamma_k = \infty$, $\sum_{k=1}^{\infty} \gamma_k^2 < \infty$? (geht nur eins)

✓

$\sum_{k=2}^{K} \frac{1}{k \ln(k)} \sim \ln(\ln(K))$

$\gamma \sim \frac{1}{\sqrt{k}}$