



Зачет 3.

Стохастическая оптимизация.

$$\min_{x \in \mathbb{R}^d} [f(x) = \mathbb{E}_{f \sim D} f(x, f)] \quad (*)$$

↑
постановка

ML + DL:

- x - параметры (веса) модели.
- f - ф-ия потерь.
- D - **природное** распределение данных.
- $f \sim$ семплирование из D .

1) Online постановка. (просто + менее понятно)

- Кнопка сверху получает информацию.
- Нет кнопки запуска !!!

2) Offline постановка.

- Информация в базе данных имеется!

┌ ML, DL - попробуем как-то приблизиться к D + получим адекватные веса модели! ┘

(*) : $f(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$ - Амурская Мон-
не-Каро que Ego f(x)

• n - размер набора

• $f_i(x)$ - i -е число на i -м элементе
набора.

↑ ↓ ↓
целым мним.

$$f_i(x) = L(g(x, f_a), f_b)$$

• $g(x, f_a)$ - объект, который вычисляет
всего одно.

• f_b - цель.

Ограниченная сумма:
finite-sum problem.

В зависимости от структуры задачи
могут меняться.

supervisor : + (координат)

by supervisor : - (маленькое не должно)

$$\text{SGD: } x_{k+1} = x_k - \eta_k \nabla f(x_k, f_k)$$

• η_k - шаг на итерации k

• $\nabla f(x_k, f_k)$ - стохастический градиент.

↳ $\nabla f(x_k, f_k) = \nabla f_i(x_k)$, i - равномерно
+ batch. размера b .]

• прегностование

- (1) Выводимость (nonconvex ✓, convex? ✓, μ -sc? X) 2023
- (2) L-smooth ???
- ↳ в 2020, Zhang, не выводится на $\mathbb{R}^d$
- пример: $f(x) = x^4$

→ оцениваем f

$$3) \mathbb{E}_{g_k} [\nabla f(x_k, g_k)] = \nabla f(x_k) \quad ? + g_k\text{-независ.?}$$

$\forall x \in \mathbb{R}^d$

RL (Markovian stochasticity),
distributed optimization

$$4) \mathbb{E}_{g_k} [\|\nabla f(x_k, g_k) - \nabla f(x_k)\|^2] \leq \sigma^2 \quad \forall x \in \mathbb{R}^d \quad ??$$

Оно inaccurate (2008-2012)

$$\bullet \sigma^2 \rightarrow \sigma^2 + A(f(x_k) - f^*) + B(\|x_k - x^*\|^2) + C\|\nabla f(x_k)\|^2$$

$$\sigma^2 = \sigma^2(x_k)$$

A fine noise

• 2020, Zhang:

$$\mathbb{E}_{g_k} [\|\nabla f(x_k, g_k) - \nabla f(x_k)\|^2] = \infty$$

the fine-tune LLM.

CNN, RNN, Transformers, LLMs - money.

Регуляризатор по α -нормированного момента:

$$\mathbb{E}_{f_k} [\|\nabla f(x_k, f_k) - \nabla f(x_k)\|^2] \leq \sigma^2$$

$\alpha \in (1, 2)$ symmetric Pareto, α -stable Levy distribution

Алгоритм 1. $f: \mu$ -sc, α -smooth, невыпуклая.
конечная генерация + разброс мин!

$$x_{k+1} = x_k - \gamma \nabla f(x_k, f_k)$$

$$\mathbb{E}[\cdot] = \mathbb{E}[\mathbb{E}[\cdot | \tilde{f}_{k-1}]]$$

$$\|x_{k+1} - x^*\|^2 = \|x_k - \gamma \nabla f(x_k, f_k) - x^*\|^2 =$$

$$= \|x_k - x^*\|^2 - 2\gamma \langle \nabla f(x_k, f_k), x_k - x^* \rangle + \gamma^2 \|\nabla f(x_k, f_k)\|^2$$

$\mathbb{E}[\mathbb{E}[X|Y]] = \mathbb{E}X$ - law of total expectation.

$$\mathbb{E}_{f_k} [\langle \nabla f(x_k, f_k), x_k - x^* \rangle] =$$

$$= \mathbb{E}_{f_k} [\langle \nabla f(x_k, f_k), x_k - x^* \rangle | x_k] =$$

$$= \mathbb{E}_{f_k} [\langle \nabla f(x_k, f_k), x_k - x^* \rangle | f_{k-1}, \dots, f_0]$$

$$\rightarrow \mathbb{E}_{f_k} [\langle \nabla f(x_k, f_k), x_k - x^* \rangle] = \langle \nabla f(x_k), x_k - x^* \rangle$$

$$\mathbb{E}_{f_k} [\|x_{k+1} - x^*\|^2] = \|x_k - x^*\|^2 - 2\gamma \langle \nabla f(x_k), x_k - x^* \rangle + \gamma^2 \mathbb{E}_{f_k} \|\nabla f(x_k, f_k)\|^2$$

$$\mathbb{E}_{f_k} \|\nabla f(x_k, f_k)\|^2 = \mathbb{E}_{f_k} \|\nabla f(x_k, f_k) - \nabla f(x_k)\|^2 + \|\nabla f(x_k)\|^2$$

$$\mathbb{E}_{f_k} [\|\nabla f(x_k, f_k) - \nabla f(x_k)\|^2 + 2 \langle \nabla f(x_k, f_k) - \nabla f(x_k), \nabla f(x_k) \rangle + \|\nabla f(x_k)\|^2]$$

$\mathbb{E}_{f_k} = 0$ re prob.

$$\mathbb{E}_{f_k} [\|x_{k+1} - x^*\|^2] = \|x_k - x^*\|^2 - 2\gamma \langle \nabla f(x_k), x_k - x^* \rangle$$

$$+ \gamma^2 \mathbb{E}_{f_k} \|\nabla f(x_k)\|^2 + \gamma^2 \mathbb{E}_{f_k} \|\nabla f(x_k, f_k) - \nabla f(x_k)\|^2$$

$\leq 0^2$

(1-3) - GD.

(4) : $\leq \sigma^2$ $\gamma \leq \frac{1}{L}$

$$\mathbb{E}_{f_k} [\|x_{k+1} - x^*\|^2] \leq (1 - \gamma\mu) \|x_k - x^*\|^2 + \gamma^2 \sigma^2$$

full expectation.

теперь: наберем первые K неравенств

$$\mathbb{E} [\|x_{k+1} - x^*\|^2] \leq (1 - \gamma\mu) \mathbb{E} \|x_k - x^*\|^2 + \gamma^2 \sigma^2$$

$$\Rightarrow \mathbb{E} \|x_K - x^*\|^2 \leq (1 - \gamma\mu)^K \|x_0 - x^*\|^2 +$$

$$+ \sum_{k=0}^{K-1} (1 - \gamma\mu)^k \gamma^2 \sigma^2 \Rightarrow$$


$$\sum_{k=0}^{K-1} q^k \leq \sum_{k=0}^{\infty} q^k = \frac{1}{1-q}$$

$$\Rightarrow \mathbb{E} \|X_k - \bar{x}\|^2 \leq \underbrace{(1 - \gamma\mu)^K}_{\text{determ.}} \|X_0 - \bar{x}\|^2 + \underbrace{\gamma \frac{\sigma^2}{\mu}}_{\text{stoch.}}$$

Оценка сходимости для SGD при $\gamma \leq \frac{1}{L}$.

Есть ли сходимость?

Мин-как будет для сходимости и
оценки!!!



2018 год: Strich.

$$\mathbb{E} \|X_k - \bar{x}\|^2 \leq \exp(-K \gamma \mu) \overset{\|X_0 - \bar{x}\|^2}{R_0^2} + \gamma \frac{\sigma^2}{\mu}$$

$$\gamma = \min\left(\frac{1}{L}, \frac{1}{\mu K} \ln\left(\frac{\mu^2 R_0^2 K}{\sigma^2}\right)\right)$$

$$1) \gamma = \frac{1}{L} : \frac{1}{L} \leq \frac{1}{\mu K} \ln(?)$$

$$C_{rit}(K) \leq \exp(-K \mu / L) R_0^2 + \frac{\sigma^2 \ln(1 - \frac{\sigma^2 \ln(1 - \frac{\sigma^2 \ln(1 - \dots))}{\mu^2 K}}{\mu^2 K} \ln(?)$$

$$2) \gamma = \frac{1}{\mu K} \ln(?)$$

$$\text{Crith}(K) \leq \exp(-\ln(?)) R_0^2 + \frac{\sigma^2}{\mu^2 K} \ln(?)$$

$$\text{Crith}(K) \leq \frac{\sigma^2}{\mu^2 K} \ln(?) + \frac{\sigma^2}{\mu^2 K} = \tilde{O}\left(\frac{\sigma^2}{\mu^2 K}\right) \leq \tilde{O}\left(\exp(-K\mu/L) R_0^2 + \frac{\sigma^2}{\mu^2 K}\right)$$

$$\exp(-\ln(?)) R_0^2 = \frac{\sigma^2}{\mu^2 K}$$

$$\exp(-\ln ?) = \frac{\sigma^2}{\mu^2 R_0^2 K}$$

$$\frac{1}{?} = \frac{\sigma^2}{\mu^2 R_0^2 K} \Rightarrow ? = \frac{\mu^2 R_0^2 K}{\sigma^2}$$

$$\Rightarrow \mathbb{E}[\|X_K - \bar{x}\|^2] = \tilde{O}\left(\exp(-K\mu/L) R_0^2 + \frac{\sigma^2}{\mu^2 K}\right)$$

✓✓✓

↑

1) $\tilde{O}$ - скрывает $\log$ factor - неважно!

2) Линейная по детерминированной части + сублинейная по стохастической части

$$3) \ln\left(\max\left(2, \frac{\mu^2 R_0^2 K}{\sigma^2}\right)\right)$$

4) Оптимален по стохастической части с точностью до $\ln: \mathcal{O}\left(\frac{\sigma^2}{\mu^2 K}\right)$

$$\mathbb{E}[\cdot] = \mathbb{E}_{\delta_0, \dots, \delta_{K-1}}[\cdot]$$

Семинор.

Какие варианты создания нового уровня оптимизации реально возможны?

1) $\mathbb{E}$.

• High-probability analysis.

$$\mathbb{P}(\|X_k - x^*\|^2 \leq \frac{1}{\dots}) \quad \text{точно!}$$

$$\mathbb{P}(\|X_k - x^*\|^2 \leq \left(\frac{1}{\dots}\right) \cdot \frac{\log\left(\frac{1}{\delta}\right)}{10^{-5}})$$

Можно более всего обобщить за 1 уровень!

SGD — некая специализация на уровне!

2023 — Sadiev.

1) Прогрессивный минимизатор: $\nabla f(x, f) \rightarrow \text{clip}_A(\nabla f(x, f))$
 $\min\left(1, \frac{1}{\|\nabla f(x, f)\|}\right) \nabla f(x, f)$

В SGD годается минимизатор,

заготовленным? 2020, Gorbunov

2) Нормализованная (Normalized SGD, Sign-SGD)

$$\text{NSGD: } x_{k+1} = x_k - \eta_k \cdot \frac{\nabla f(x_k)}{\|\nabla f(x_k)\|}$$

Hubler, 2024/2025. ✓

$$\text{Sign SGD: } x_{k+1} = x_k - \eta_k \cdot \text{sign}(\nabla f(x_k))$$

Kornilov 2025 ✓

(предельно малого размера шага)

2) Предположение.

L -smooth и конвексная функция

$$\bullet \|\nabla f(y) - \nabla f(x)\| \leq L \|y - x\| \quad \forall y, x \in \mathbb{R}^d$$

$$f(x) \sim \frac{L}{2} \|x\|^2$$

$$f(x) = x^4 \quad f(x) = \frac{e^x + e^{-x}}{2}$$

$$\bullet \|\nabla f(y) - \nabla f(x)\| \leq (L_0 + L \sup_{u \in [x, y]} \|\nabla f(u)\|) \|y - x\|$$

2020, Zhang

Предположение выполняется не на всех функциях, содержащих элементы негладкости

3) $f_k = ?$

• теор. забывчивость от K . !!!

• Параметры задачи L, μ, R_0, σ

$$\|\nabla^2 f(x)\|_2 \leq L$$

$$\hat{L} = \sup_{x \in \mathbb{R}^d} \|\nabla^2 f(x)\|_2$$

R_0 : расстояние между x^*

σ : га константа в граде!

Parameter-free optimization

D-adaptation (2022) - best paper award.

Sign-SGD: Medvedev 2026.

Dog, Dowlg - не помню.

1) $f_k = \frac{1}{k^p + \Delta}$ - константа max. ✓

2) Сложность работы: Архивко, Вульс, Тарасович. ???

3) $f_k = \arg \min f(x_k - \gamma \nabla f(x_k, f_k))$?

1)* Step-decay. (2019)

Day 6 log K: $f_{k+1} = \frac{f_k}{2}$.

5)* Warm-up + cosine annealing (1950x)

↓
теор. гарантия на вогнутости
функции потерь

Использование неверно!

На Torch

$$f_k = f \cdot \cos.$$

Уменьшение

пошагово.

$$\frac{1}{\cos}$$

Metaoptimization

4) Критерии сходимости.

Хотим иметь сходимость по последней итерации!

f : convex, L -smooth, несмещ, выпукл,
конечная граница. Method: SGD

$$\Phi_k = d_k (f(x_k) - f^*) + L \|x_k - x^*\|^2$$

$$d_0 = 0, \quad \underline{d_{k+1} = d_k + \eta L f_k}$$

$$\begin{aligned} \Phi_{k+1} - \Phi_k &= d_{k+1} (f(x_{k+1}) - f^*) - d_k (f(x_k) - f^*) \\ &\quad + L (\|x_{k+1} - x^*\|^2 - \|x_k - x^*\|^2) = \end{aligned}$$

$$= d_{k+1} (f(x_{k+1}) - f(x_k)) + (d_{k+1} - d_k) (f(x_k) - f^*) \\ + L (2 \langle x_{k+1} - x_k, x_k - x^* \rangle + \|x_{k+1} - x_k\|^2)$$

L-smooth

convexity

$$= d_{k+1} (f(x_{k+1}) - f(x_k)) + (d_{k+1} - d_k) (f(x_k) - f^*) \\ + L (- 2 \gamma_k \langle \nabla f(x_{k, g_k}), x_k - x^* \rangle + \gamma_k^2 \|\nabla f(x_{k, g_k})\|^2)$$

$$\Rightarrow \mathbb{E}_{g_k} [\Phi_{k+1} - \Phi_k] \leq - \gamma_k \nabla f(x_k) \textcircled{1} - \gamma_k \nabla f(x_{k, g_k}) \\ \leq d_{k+1} \mathbb{E}_{g_k} (\langle \nabla f(x_k), x_{k+1} - x_k \rangle + \frac{L}{2} \|x_{k+1} - x_k\|^2) \\ + (d_{k+1} - d_k) \langle \nabla f(x_k), x_k - x^* \rangle + \\ + L (- 2 \gamma_k \langle \nabla f(x_k), x_k - x^* \rangle + \gamma_k^2 (\|\nabla f(x_k)\|^2 + \sigma^2))$$

$$= d_{k+1} (- \gamma_k \|\nabla f(x_k)\|^2 + \frac{L \gamma_k^2}{2} (\|\nabla f(x_k)\|^2 + \sigma^2)) \\ + (d_{k+1} - d_k - 2 \gamma_k L) \langle -11- \rangle \\ + L \gamma_k^2 \|\nabla f(x_k)\|^2 + L \gamma_k^2 \sigma^2$$

$$= d_{k+1} (- \gamma_k \|\nabla f(x_k)\|^2 + \frac{L \gamma_k^2}{2} \|\nabla f(x_k)\|^2) + \\ + d_{k+1} \frac{L \gamma_k^2}{2} \sigma^2 + 2 \gamma_k^2 \|\nabla f(x_k)\|^2 + L \gamma_k^2 \sigma^2 \textcircled{\leq} \quad \gamma_k \leq \frac{1}{L}$$

$$(1) \gamma_k \leq \frac{1}{2} \Rightarrow -\gamma_k + \frac{L\gamma_k^2}{2} \leq -\frac{\gamma_k^2}{2}$$

$$2) \quad -\frac{d_{k+1}}{2} \gamma_k + L\gamma_k^2 = -\frac{d_k}{2} \gamma_k - 2\gamma_k^2 + L\gamma_k^2 \\ = -\frac{d_k \gamma_k}{2} \leq 0$$

$$\leq d_{k+1} \frac{L\gamma_k^2}{2} \sigma^2 + L\gamma_k^2 \sigma^2 \Rightarrow$$

$$\mathbb{E}_{\mathcal{F}_k} (\varphi_{k+1} - \varphi_k) \leq \underline{d_{k+1} L \gamma_k^2 \sigma^2 + L \gamma_k^2 \sigma^2}$$

$$d_{k+1} = \sum_{t=0}^k 2\gamma_t L \leq$$

$$\gamma_t = \min\left(\frac{1}{t}, \frac{\beta}{(t+1)^R}\right)$$

$$\leq \sum_{t=0}^k \frac{2L\beta}{(t+1)^R} \leq$$

$$\leq \underline{CL\beta(k+1)^{1-R}}$$

pour app. maximum
regret on y a
stoch.

$$\sum_{t=0}^k \frac{1}{(t+1)^R} = \Theta(k^{1-R})$$

β ne converge pas à 1

$$\mathbb{E}_{\mathcal{F}_k} (\varphi_{k+1} - \varphi_k) \leq CL\beta L\gamma_k^2 \sigma^2 (k+1)^{1-R} + L\gamma_k^2 \sigma^2$$

Théorème: $\mathbb{E}$ est sous-additif.

$$\mathbb{E}(\varphi_k) \leq \varphi_0 + \sum_{k=0}^{K-1} (CL\beta L\gamma_k^2 \sigma^2 (k+1)^{1-R} + L\gamma_k^2 \sigma^2) \quad \textcircled{C}$$

$$\varphi_0 = LR_0^2$$

$$\textcircled{5} \quad \underbrace{\Phi_0 + \sum_{k=0}^{K-1} \left(\underbrace{CL^2 B^3 \sigma^2}_{(k+1)^{3\beta-1}} + \frac{LB^2 \sigma^2}{(k+1)^{2\beta}} \right)}_{\leq} \textcircled{5}$$

Угел: Φ_0 и правая часть совпадают.

$$B = \min\left(\frac{R_0}{\sigma}, \frac{R_0^{2/3}}{\sigma^{2/3} L^{1/3}}\right)$$

$$\beta = \frac{2}{3} \Rightarrow RHS \approx LR_0^2 \ln(K)$$

$$\mathbb{E} \Phi_K = O(LR_0^2 \ln K)$$

∥

$$d_K \mathbb{E}(f(x_K) - f^*)$$

$$\mathbb{E}(f(x_K) - f^*) = O\left(\frac{LR_0^2 \ln(K)}{d_K}\right)$$

$$1) \quad d_K = \sum_{k=0}^{K-1} \alpha_k L$$

$$2) \quad \frac{1}{\sum_{k=0}^{K-1} \alpha_k} \leq \frac{\sum_{k=0}^{K-1} \frac{1}{\alpha_k}}{K^2} \quad \left(\text{неравенство о среднем} \right)$$

$$3) \quad \frac{1}{\alpha_k} = \max\left(L, \frac{(k+1)^\beta}{B}\right) \leq \left(L + \frac{(k+1)^\beta}{B} \right)$$

$$\mathbb{E}(f(x_K) - f^*) = \tilde{O}\left(\frac{LR_0^2}{K} + \frac{\max(R_0 \sigma, R_0^{4/3} L^{1/3} \sigma^{2/3})}{K^{1/3}}\right)$$

7
re omnia sunt