Занятие 6. Variance Reduction

$$\min \left[f(x) = \mathbb{E}_{\xi \sim D} f(x, \xi) \right]$$ — общая

↑ × finite-sum

↘ $$\min_{x \in \mathbb{R}^d} \left\{ f(x) = \frac{1}{n} \sum_{i=1}^{n} f_i(x) \right\}$$ — сегодня

$\nabla f(x, \xi) \to \nabla f_i(x)$ / возможен данн. в.

Если f — μ-sc + L-гладкая → скорость SGD — сублинейная! $\tilde{O}\left(\frac{1}{k}\right)$

Идея: хочу иметь g_k — estimator:

$g_k \to \nabla f(x^*) = 0$ ← ???

$x_{k+1} = x_k - \gamma g_k$

1) SAG. (2013) ✗

2) SAGA (2013-2014) ✓

Момент k: храню матрицу. слож. град. $i_k \sim U[1, n]$ ← момент k

$y_{i_k}^k$ ← случ. инд. на k итерации.

$$d \left\{ \left(y_{i_k}^{k+1} = \nabla f_{i_k}(x_k) \right) \right\}$$

(1)

$1, n$ $\quad$ i_k

SAGA: $g_k = \nabla f_{i_k}(x_k) - y_{i_k}^k + \frac{1}{n}\sum_{i=1}^n y_i^k$

$$y_i^{k+1} = \begin{cases} \nabla f_i(x_k), & i = i_k \quad (1) \\ y_i^k, & i \neq i_k \end{cases}$$

память!

$$x_{k+1} = x_k - \gamma g_k$$

$$\mathbb{E}[g_k \mid x_k] = \frac{1}{n}\sum_{i=1}^n \nabla f_i(x_k) - \frac{1}{n}\sum_{i=1}^n y_i^k + \frac{1}{n}\sum_{i=1}^n y_i^k$$

$$= \nabla f(x_k) \quad (*)$$

SAGA – несмещенный (!!!) estimator.

Сходимость – ?

f_i – L – гладкие + f – μ – сильно выпуклая.

$$\|x_{k+1} - x^*\|^2 = \|x_k - x^*\|^2 - 2\gamma\langle g_k, x_k - x^*\rangle + \gamma^2\|g_k - \nabla f(x^*)\|^2$$

$$\mathbb{E}_k[\|x_{k+1} - x^*\|^2] = \|x_k - x^*\|^2 - 2\gamma\langle \nabla f(x_k), x_k - x^*\rangle + \gamma^2\mathbb{E}_k\|g_k - \nabla f(x^*)\|^2$$

$\nabla f(x^*) = 0$, $(*)$

$$\mathbb{E}_k\|g_k - \nabla f(x^*)\|^2 =$$

$$= \mathbb{E}_k\left[\left\|\nabla f_{i_k}(x_k) - y_{i_k}^k + \frac{1}{n}\sum_{i=1}^n y_i^k - \nabla f(x^*)\right\|^2\right]$$

$$= \mathbb{E}_k\Big[\Big\| \nabla f_{i_k}(x_k) - \nabla f_{i_k}(x^*) + \nabla f_{i_k}(x^*) - y_{i_k}^k + \frac{1}{n}\sum_{i=1}^n y_i^k - \nabla f(x^*)\Big\|^2\Big]$$

$\|a+b\|^2 \le 2\|a\|^2 + 2\|b\|^2$

$$\le 2\mathbb{E}_k\Big[\|\nabla f_{i_k}(x_k) - \nabla f_{i_k}(x^*)\|^2\Big] + 2\mathbb{E}_k\Big[\Big\|\nabla f_{i_k}(x^*) - y_{i_k}^k - \Big(\nabla f(x^*) - \frac{1}{n}\sum_{i=1}^n y_i^k\Big)\Big\|^2\Big]$$

ξ_k; $\mathbb{E}_{i_k}\xi_k = \frac{1}{n}\sum_{i=1}^n \nabla f_i(x^*) = \nabla f(x^*)$

$\mathbb{E}\|\xi - \mathbb{E}\xi\|^2 \le \mathbb{E}\|\xi\|^2$

$$\le 2\mathbb{E}_k\|\nabla f_{i_k}(x_k) - \nabla f_{i_k}(x^*)\|^2 + 2\mathbb{E}_k\|\nabla f_{i_k}(x^*) - y_{i_k}^k\|^2$$

← пока забудем

$$\|\nabla f_i(x_k) - \nabla f_{i_k}(x^*)\|^2 \le 2\Big[\Big(\frac{1}{n}\sum f_{i_k}(x_k) - \frac{1}{n}\sum f_{i_k}(x^*) - \frac{1}{n}\sum \nabla f_{i_k}(x^*), x_k - x^*\Big)\Big]$$

$$\le 4L\Big(f(x_k) - f^*\Big) + \frac{2}{n}\sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|^2$$

Вернёмся к подготовке: μ-сс. $-\langle \nabla f(x_k), x_k - x^*\rangle \le -(f(x_k) - f^*) - \frac{\mu}{2}\|x_k - x^*\|^2$

$$\mathbb{E}_k\|x_{k+1} - x^*\|^2 \le (1 - \gamma\mu)\|x_k - x^*\|^2 - 2\gamma(f(x_k) - f^*) + \gamma^2\Big(4L(f(x_k) - f^*) + \frac{2}{n}\sum_{i=1}^n \|\nabla f_i(x^*) - y_i^k\|^2\Big)$$

σ_k^2

$$\mathbb{E}_k\Big[\frac{1}{n}\sum_{i=1}^n \|y_i^{k+1} - \nabla f_i(x^*)\|^2\Big] = \sigma_{k+1}^2$$

$$= \Big(1 - \frac{1}{n}\Big)\cdot\frac{1}{n}\sum_{i=1}^n \|y_i^k - \nabla f_i(x^*)\|^2 + \cdots$$

σ_k^2

$$+ \frac{1}{n}\cdot\frac{1}{n}\sum_{i=1}^{n}\|\nabla f_i(x_k)-\nabla f_i(x^*)\|^2 \Rightarrow$$

что мы сами.

$$\boxed{\mathbb{E}_k\,\sigma_{k+1}^2 \le \left(1-\frac{1}{n}\right)\sigma_k^2 + \frac{2L}{n}\left(f(x_k)-f^*\right)}$$

$$\cdot M\gamma^2 \Rightarrow$$

$$\mathbb{E}_k\left[\|x_{k+1}-x^*\|^2\right] + M\gamma^2\mathbb{E}_k\sigma_{k+1}^2 \le (1-\gamma\mu)\|x_k-x^*\|^2$$
$$- 2\gamma\left(1-2L\gamma-\frac{\gamma ML}{n}\right)\left(f(x_k)-f^*\right)$$
$$+\left(\left(1-\frac{1}{n}\right)M\gamma^2+2n\gamma^2\right)\sigma_k^2$$

$M = 4n \Rightarrow$ 1) $-2\gamma(1-2L\gamma-4L\gamma) = -2\gamma(1-6L\gamma)$

2) $\left(\left(1-\frac{1}{n}\right)+\frac{2n\gamma^2}{M\gamma^2}\right)M\gamma^2 =$

$$= \left(1-\frac{1}{n}+\frac{1}{2n}\right)M\gamma^2$$

$$\gamma \le \frac{1}{6L}$$

$$\mathbb{E}_k\left[\|x_{k+1}-x^*\|^2\right] + M\gamma^2\mathbb{E}_k\sigma_{k+1}^2 \le$$
$$\le (1-\gamma\mu)\|x_k-x^*\|^2 + \left(1-\frac{1}{2n}\right)M\gamma^2\sigma_k^2$$
$$\le \max\left(1-\gamma\mu,\ 1-\frac{1}{2n}\right)\cdot\underbrace{\left(\|x_k-x^*\|^2 + M\gamma^2\sigma_k^2\right)}_{V_k}$$

$$\mathbb{E}_k V_{k+1} \le \underbrace{\max\left(1-\gamma\mu,\ 1-\frac{1}{2n}\right)}_{\rho} V_k$$

Раскрутим до V_0 и навешу полное матож.

$\Rightarrow$

$\mathbb{E} V_k \le \rho^k V_0$

1) Очень важная инициализация:

$$V_0 = \|x_0 - x^*\|^2 + \frac{M\gamma^2}{n} \sum_{i=1}^{n} \|y_i^0 - \nabla f_i(x^*)\|^2$$

2) $1 - x \le \exp(-x)$ => оценка сходимости.

$$\Rightarrow K = O\left(\left(n + \frac{L}{\mu}\right) \log \frac{V_0}{\varepsilon}\right) \checkmark$$

3) Память! $O(nd)$

Метод SVRG (2014)

1) Inner / outer loop.

Inner: $k = 0, \dots, N-1$

$i_k \sim U[1, n]$

$$g_k = \nabla f_{i_k}(x_k) - \nabla f_{i_k}(w_t) + \nabla f(w_t)$$

trouble.

$$x_{k+1} = x_k - \gamma g_k.$$

Outer: $t = 0, \dots, T-1$.

$w_{t+1} = x_k$.

↖ рекурсивная штука.

1) Рекурсивность.

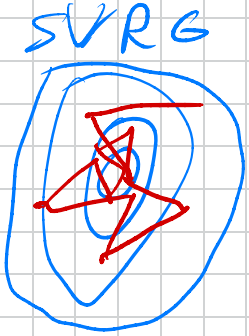
2) $K = O\left(\left(n + \frac{L}{\mu}\right) \log \frac{V_0}{\varepsilon}\right)$

3) $O(d)$ памяти!

4) Приходится считать full grad.

5)* Неадаптивность.

SARAH (?)





Outer loop: $t \in \overline{0, T-1}$

$x_0 := x_k$ $\quad g_{-1} = \nabla f(x_0)$

Inner loop: $k \in \overline{0, K-1}$

$$g_k = \nabla f_{i_k}(x_k) - \nabla f_{i_k}(x_{k-1}) + g_{k-1}$$

$$x_{k+1} = x_k - \gamma g_k$$

$n \to \frac{n}{6}$.

1) Сильная!

2) $K = O\left(\left(n + \frac{L}{\mu}\right) \log \frac{V_0}{\varepsilon}\right)$

3) $O(d)$ памяти

4) Устойчивее SVRG

5) Снимаем full grad.

SVRG → L-SVRG.

SARAH → PAGE. (2021)

$$x_{k+1} = x_k - \gamma \cdot \begin{cases} g_k & \text{с вер } 1-p \\ \nabla f(x_k) & \text{с вер } p. \end{cases}$$

$\mathbb{E}\sum$ |inner loop| $= \frac{1}{p}$.

Katyusha (2015/16, Allen-Zhou)

$$K = O\left(\sqrt{\mu \frac{L}{\mu}} \log \frac{V_0}{\varepsilon}\right)$$

$$\left(\frac{\mu + \frac{L}{\mu}}{2} \geq \sqrt{\mu \frac{L}{\mu}}\right)$$

Добавим ускорение.

1) Unified iteration.

$g_k \to g_k(x_k, f_k, \text{history})$

$x_{k+1} = x_k - \gamma g_k$

Теперь Nonconvex (?)

1) $\mathbb{E}_k\left[\|g_k - \nabla f(x_k)\|^2\right] \le (1-\rho_1)\|g_{k-1} - \nabla f(x_{k-1})\|^2 + A\sigma_{k-1}^2 + BL^2\|x_k - x_{k-1}\|^2$

2) $\mathbb{E}_k\left[\sigma_k^2\right] \le (1-\rho_2)\sigma_{k-1}^2 + CL^2\|x_k - x_{k-1}\|^2$

SVRG, SAGA, SARAH — удовл. 1) и 2)

SAGA: $A = 1 + \frac{1}{2n}$, $B = 1 + 2n$, $C = 2n$

$\rho_1 = 1$, $\rho_2 = \frac{1}{2n}$

$\sigma_k^2 = \frac{1}{n}\sum_{i=1}^{n}\|\nabla f_i(x^*) - y_i^k\|^2$

Convex:

$A = 1$, $\rho_2 = 1$

Sketching (2018, Mishchenko)

2) Unified estimator

$\nabla f(x) \to S^T \nabla f(x)$, $S \in \mathbb{R}^{d\times d}$ — стохастически из некоторого D.

$\|x\|_2 \to \|x\|_B = \sqrt{\langle x, Bx\rangle}$, $B \succ 0$

Полный estimator: на итерации k

$h_{kel} = \arg\min_{h\in\mathbb{R}^d} \|h - h_k\|_B^2$ (*)

s.t. $S_k^T h = S_k^T \nabla f(x_k)$

VR? — наши

Метод Ландвебера.

$$h_{k+1} = h_k - B^{-1} Z_k (h_k - \nabla f(x_k))$$

$$Z_k = S_k (S_k^T B^{-1} S_k)^{\dagger} S_k^T$$

$\Downarrow$

Σ biased.

$$(\Sigma - B^{-1} Z_k) h_k + B^{-1} Z_k \nabla f(x_k)$$

Хочу unbiased estimator:

$\theta_k = \theta_k(S_k)$; $\mathbb{E}[\theta_k Z_k] = B$

$\uparrow$ число.

$$g_k = (1-\theta_k) h_k + \theta_k h_{k+1} = B^{-1} \mathbb{E}_k[\theta_k Z_k]$$

$$= h_k + \theta_k B^{-1} Z_k (\nabla f(x_k) - h_k)$$

$\mathbb{E}_k g_k = \nabla f(x_k)$ — несмещённый оператор.

$$\begin{cases} g_k = h_k + \theta_k B^{-1} Z_k (\nabla f(x_k) - h_k) \\ x_{k+1} = x_k - \gamma g_k \\ h_{k+1} = h_k + B^{-1} Z_k (\nabla f(x_k) - h_k) \end{cases}$$

Sketching iteration.

Пример. $i_k \in \overline{1,d}$ i_k имеет вер p_{i_k}

$\Downarrow$

e_{i_k}, $i_k \in \overline{1,d}$, i_k с вер p_{i_k}

S_k ⇓

$Z_k(S_k, B) = e_{i_k} e_{i_k}^T$, $i_k \in \overline{1,d}$, i_k с вер p_{i_k}

$h_{k+1} = h_k + Z_k(\nabla f_{i_k}(x_k) - h_k)$

$\theta_k = \frac{1}{p_{i_k}}$ с вер p_{i_k}

$$\mathbb{E}[\theta_k Z_k] = \sum_{i=1}^{d} p_i \cdot \frac{1}{p_i} e_i e_i^T \left(e_i e_i^T B e_i e_i^T\right)^{-1}$$

$e_i e_i^T$

$= B.$

$S_k = e_{i_k} e_{i_k}^T$ — стох матрица ⇒

⇒ алгоритм **SEGA**

Насколько все можно на практике?

Defazio (2018)

SVRG: $g_k = \nabla f_{i_k}(x_k) - \nabla f_{i_k}(w_k) + \nabla f(w_k)$

x_k — текущая внешняя точка

w_k — точка внешнего цикла