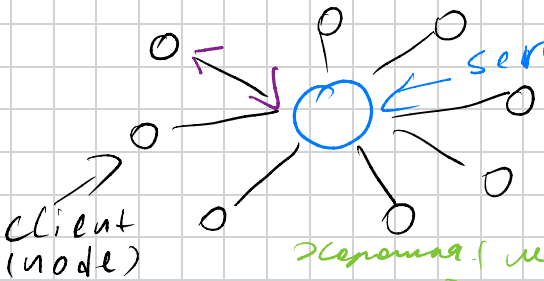
Занятие 7. Распределённая оптимизация

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{M} \sum_{m=1}^{M} f_m(x)$$ — лосс. M — сколько клиентов

$$f_m(x) = \frac{1}{N_m} \sum_{i=1}^{N_m} \ell(g(x, D_m), a_i^m)$$

N_m — размер выборки. $g(x, D_m)$ — выход модели. a_i^m — данные m-ого клиента.

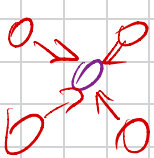


Сервер ⟷ Клиент (экономия (мало времени))

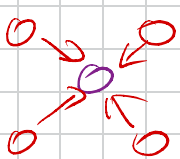
можно! (на пару порядков больше) ×10/100

сегодня!

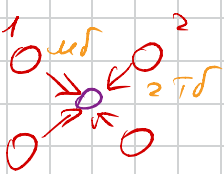
Коммуникационные раунды (Медленно)



Коммуникаций (синхр. + асинхронно)



Биты (количество информации) <=> время.



4 Parallel GD. (1953)

$k = 0, \ldots, K-1$

Client: вычисляет $\nabla f_m(x_k)$

→ передает на сервер

$$x_{k+1} = x_k - \gamma \underbrace{\frac{1}{M}\sum_{m=1}^{M} \nabla f_m(x_k)}_{\nabla f(x_k)}$$

Server → clients : x_{k+1}.

К. м коммуникаций + передавать $\nabla f(x)$ долго.

---

1) Unbiased compression. $\omega \geq 1$

$$\boxed{\mathbb{E}\, Q(x) = x \;;\; \mathbb{E}\|Q(x) - x\|^2 \leq (\omega - 1)\|x\|^2}$$

$Q(x)$ — сжатие объекта x.

- $\omega = 1 \Leftrightarrow Q(x) = x$ → ω — параметр сжатия

Примеры: 1) Rand k (x) — вектор

$x \in \mathbb{R}^d$, но в среду k случайных координат (из равномерного)

$$\text{Rand k}(x) = \frac{d}{k} \sum_{i \in B} [x]_i e_i, \quad B \text{ — случ. мн-во размера } k \text{ из } \overline{1,d}$$

$$\omega = \frac{d}{k}.$$

2) Rand Rou d (x) → округляем случайно к ближ. 2^u

Q-GD.

Client: $Q(\nabla f_m(x_k))$ → на сервер.

Server: $x_{k+1} = x_k - \gamma \frac{1}{M} \sum_{m=1}^{M} Q(\nabla f_m(x_k))$

---

f_m – μ-sc и L-smooth, + Q.

$$\mathbb{E}\left[\|x_{k+1} - x^*\|^2\right] \le (1-\mu\gamma)\,\mathbb{E}\left[\|x_k - x^*\|^2\right] + \frac{2\gamma^2\omega}{M^2} \sum_{m=1}^{M} \|\nabla f_m(x^*)\|^2$$

GD: $x \to x^*$; $\nabla f \to 0$

SGD: $x \to x^*$; $\nabla f(g) \not\to 0$

VR: $g \to \nabla f(x^*) = 0$

$\|Q(\nabla f_m) - \nabla f_m\| \to 0$ класс VR.

---

2) DIANA (Mishchenko) 2019

$k = 0, \dots, K-1$

client: 1) $\Delta_m^k = \nabla f_m(x_k) - h_m^k$ ✓

✓ 2) $\hat{\Delta}_m^k = Q(\Delta_m^k)$

3) $h_m^{k+1} = h_m^k + \alpha \hat{\Delta}_m^k$ — можно не.

могу на сервер → ✓ 4) $\hat{g}_m^k = h_m^k + \hat{\Delta}_m^k$ → отправляю на сервер.

Server: $\hat{g}^k = \frac{1}{M} \sum_{m=1}^{M} \hat{g}_m^k$

$x_{k+1} = x_k - \gamma \tilde{g}^k$ → на кластерах.

- $\tilde{\Delta}^k = \frac{1}{M}\sum_{m=1}^{M} \hat{\Delta}_m^k$, $\tilde{g}^k$ – введено, $h^k = \frac{1}{M}\sum_{m=1}^{M} h_m^k$.

$$\mathbb{E}_k\left[\|x_{k+1} - x^*\|^2\right] = \|x_k - x^*\|^2 - 2\gamma \mathbb{E}_k \langle \tilde{g}^k, x_k - x^* \rangle + \gamma^2 \mathbb{E}_k\left[\|\tilde{g}^k\|^2\right] \quad (=)$$

$$\mathbb{E}_k \hat{g}_m^k = \mathbb{E}_k\left[h_m^k + \hat{\Delta}_m^k\right] = \mathbb{E}_k\left[h_m^k + Q\left(\nabla f_m(x_k) - h_m^k\right)\right] = \nabla f_m(x_k) \quad \checkmark$$

$(=)$ $\|x_k - x^*\|^2 - 2\gamma \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \gamma^2 \mathbb{E}_k\left[\|\tilde{g}^k\|^2\right]$

$$\nabla f(x_k) - \nabla f(x^*) = \frac{1}{M}\sum_{m=1}^{M}\left(\nabla f_m(x_k) - \nabla f_m(x^*)\right)$$

$$\langle \nabla f_m(x_k) - \nabla f_m(x^*), x_k - x^* \rangle \geq \frac{\mu L}{\mu + L}\|x_k - x^*\|^2 + \frac{1}{\mu + L}\|\nabla f_m(x_k) - \nabla f_m(x^*)\|^2$$

$$\mathbb{E}_k\left[\|x_{k+1} - x^*\|^2\right] \leq \left(1 - \frac{2\gamma\mu L}{\mu + L}\right)\|x_k - x^*\|^2 - \frac{2\gamma}{\mu + L}\frac{1}{M}\sum_{m=1}^{M}\|\nabla f_m(x_k) - \nabla f_m(x^*)\|^2 + \gamma^2 \mathbb{E}_k\left[\|\tilde{g}^k - \nabla f(x^*)\|^2\right]$$

ок?

$\pm \nabla f(x_k)$?

$$\mathbb{E}_k\left[\|\tilde{g}^k - \nabla f(x^*)\|^2\right] = \mathbb{E}_k\left[\|\tilde{g}^k - \nabla f(x_k)\|^2\right] + \|\nabla f(x_k) - \nabla f(x^*)\|^2 \quad (\leq)$$

(1) $\mathbb{E}\tilde{g}^k = \nabla f(x_k)$

(2) $\left\|\frac{1}{M}\sum_{m=1}^{M}\hat{g}_m^k - \nabla f_m(x_k)\right\|^2 \frac{1}{M}\sum_{m=1}^{M}\|\nabla f_m(x_k) - \nabla f_m(x^*)\|^2$ (4)

$(=)$

$$\leq \frac{1}{M^2}\sum_{m=1}^{M}\mathbb{E}_k\left[\|\hat{g}_m^k-\nabla f_m(x_k)\|^2\right] \quad (1)$$

$$+\frac{1}{M}\sum_{m=1}^{M}\|\nabla f_m(x_k)-\nabla f_m(x^*)\|^2 \quad (2)$$

$$\leq \frac{1}{M^2}\sum_{m=1}^{M}\mathbb{E}_k\|\hat{g}_m^k-\nabla f_m(x_k)\|^2+\frac{1}{M^2}\sum_{i\neq j}\mathbb{E}\langle \hat{g}_i^k-\nabla f_i(x_k),\hat{g}_j^k-\nabla f_j(x_k)\rangle$$

независимость компонентов

$$\leq \frac{1}{M^2}\sum_{m=1}^{M}\mathbb{E}_k\left[\|h_m^k+\hat{\Delta}_m^k-\nabla f_m(x_k)\|^2\right]$$

$$-\Delta_m^k$$

$$+\frac{1}{M}\sum_{m=1}^{M}\|\nabla f_m(x_k)-\nabla f_m(x^*)\|^2$$

$$Q(\Delta_m^k)$$

$$=\frac{1}{M^2}\sum_{m=1}^{M}\mathbb{E}_k\left[\|\hat{\Delta}_m^k-\Delta_m^k\|^2\right]+$$

$$+\frac{1}{M}\sum_{m=1}^{M}\|\nabla f_m(x_k)-\nabla f_m(x^*)\|^2$$

$$\leq \frac{\omega}{M^2}\sum_{m=1}^{M}\|\Delta_m^k\|^2+\frac{1}{M}\sum_{m=1}^{M}\|\nabla f_m(x_k)-\nabla f_m(x^*)\|^2 \quad (3)$$

$$\nabla f_m(x_k)-h_m^k=\nabla f_m(x_k)-\nabla f_m(x^k)+\nabla f_m(x^k)-h_m^k$$

$$\leq \frac{2\omega}{M^2}\sum_{m=1}^{M}\|\nabla f_m(x_k)-\nabla f_m(x^*)\|^2+\frac{2\omega}{M^2}\sum_{m=1}^{M}\|h_m^k-\nabla f_m(x^k)\|^2$$

$$+\frac{1}{M}\sum_{m=1}^{M}\|\nabla f_m(x_k)-\nabla f_m(x^*)\|^2=$$

$$=\left(1+\frac{2\omega}{M}\right)\frac{1}{M}\sum_{m=1}^{M}\|\nabla f_m(x_k)-\nabla f_m(x^*)\|^2$$

$$+\frac{2\omega}{M^2}\sum_{m=1}^{M}\|h_m^k-\nabla f_m(x^k)\|^2$$

$$\mathbb{E}_k\|h_m^{k+1}-\nabla f_m(x^k)\|^2=\mathbb{E}_k\left[\|h_m^k+\alpha\hat{\Delta}_m^k-\nabla f_m(x^k)\|^2\right]$$

$$\leq \|h_m^k-\nabla f_m(x^k)\|^2+\alpha^2\omega\|\Delta_m^k\|^2$$

$$+2\alpha\langle \Delta_m^k,\ h_m^k-\nabla f_m(x^k)\rangle \quad (4)$$

$$-\nabla f_m(x_k)$$

$\leq \mathbb{E}_k\big[\| h_m^k - \nabla f_m(x^k)\|^2 + \alpha^2 \|\Delta_m^k\|^2$

$+ 2\alpha \langle \hat{\Delta}_m^k,\ h_m^k - \nabla f_m(x^k)\rangle\big]$

$\mathbb{E}_k \hat{\Delta}_m^k = \Delta_m^k$

$\mathbb{E}_k \|\hat{\Delta}_m^k - \Delta_m^k\|^2 \leq (\omega - 1)\|\Delta_m^k\|^2$

$+ \|\Delta_m^k\|^2 \qquad \omega \|\Delta_m^k\|^2$

$\mathbb{E}_k \|\Delta_m^k\|^2$

$\leq \|h_m^k - \nabla f_m(x^k)\|^2 + \alpha^2 \omega \|\Delta_m^k\|^2 + \qquad \alpha\omega \leq 1$

$\leq \alpha$; $= \|-\nabla f_m(x^k) + h_m^k\|^2$

$+ 2\alpha \langle \Delta_m^k,\ h_m^k - \nabla f_m(x_k)\rangle$; $= -\Delta_m^k$

$+ 2\alpha \langle \Delta_m^k,\ \nabla f_m(x_k) - \nabla f_m(x^k)\rangle$

$\leq \|h_m^k - \nabla f_m(x^k)\|^2 - \alpha \|\Delta_m^k\|^2$

$+ 2\alpha \langle \Delta_m^k,\ \nabla f_m(x_k) - \nabla f_m(x^*)\rangle$

$\mathbb{E}_k\big[\|h_m^{k+1} - \nabla f_m(x^k)\|^2\big] \leq \|h_m^k - \nabla f_m(x^k)\|^2 - \alpha\|\Delta_m^k\|^2$

$+ \alpha \langle \Delta_m^k,\ 2\nabla f_m(x_k) - 2\nabla f_m(x^k)\rangle$ $\Leftrightarrow$ $\langle \Delta_m^k, -\nabla f_m(x_k) + h_m^k\rangle$

$= \|h_m^k - \nabla f_m(x^k)\|^2 + \alpha \langle \nabla f_m(x_k) - h_m^k,\ \nabla f_m(x_k) + h_m^k - 2\nabla f_m(x^k)\rangle$

$-\nabla f_m(x^k)$; Δ_m^k

1. B

$\leq (1-\alpha)\|h_m^k - \nabla f_m(x^k)\|^2 + \alpha\|\nabla f_m(x_k) - \nabla f_m(x^k)\|^2$

$\mathbb{E}_k[\|x_{k+1} - x^*\|^2] \leq \left(1 - \frac{2\gamma\mu L}{\mu + L}\right)\|x_k - x^*\|^2 +$

$+ \left(\gamma^2\left(1 + \frac{2\omega}{M}\right) - \frac{2\gamma}{\mu + L}\right)\frac{1}{M}\sum_{m=1}^{M}\|\nabla f_m(x_k) - \nabla f_m(x^*)\|^2$

$+ \frac{2\gamma^2\omega}{M^2}\sum_{m=1}^{M}\|h_m^k - \nabla f_m(x^*)\|$

$+$ k others summands

$B, \gamma, \alpha \Rightarrow$

$\leftarrow$ ф-ия Ляпунова как в SAGA.

$$\mathbb{E}_k \Phi_{k+1} \le \left(1 - \frac{\gamma\mu L \alpha}{\mu + L}\right) \Phi_k.$$

$$K = O\left(\left(1 + \frac{w}{m}\right)\frac{L}{\mu}\log\frac{\Phi_0}{\varepsilon}\right)$$ итерации.

$K \to \frac{K}{\gamma w}$ и сколько битов

$w \sim \gamma w$ эффективный сплав.

дальше.

$$O\left(\left(\frac{1}{w} + \frac{1}{m}\right)\frac{L}{\mu}\log\frac{\Phi_0}{\varepsilon}\right)$$

$w \ge m$

Unbiased - можно! biased - как ф!

$\beta \ge 1.$

$$\mathbb{E}\left[\|C(x) - x\|^2\right] \le \left(1 - \frac{1}{\beta}\right)\|x\|^2$$

1) Top $k(x)$ – k самых по $|\cdot|$ координат.

2) Round (x) – округление до ближайшей степени двойки.

3) $sign(x)\,\|x\|_2$

! Если $\nexists\, C(x) \Rightarrow$ существуют работы: QGD – расходится (Безносиков, 2021, „on biased")

2014 zeg (Microsoft), Error feedback (EF)

client: $g_m^k = C\left(\nabla f_m(x_k) + e_m^k\right) \to$ server.

local: $e_m^{k+1} = e_m^k + \nabla f_m(x_k) - C\left(\nabla f_m(x_k) + e_m^k\right)$

server: $x_{k+1} = x_k - \gamma \frac{1}{M}\sum_{m=1}^{M} g_m^k$

x_{k+1} — по линейке

2018 (Stich): nonconvex, conv, sc, но для одного клиента!

Вторая последовательность

$\hat{x}_k = x_k - \gamma e^k = x_k - \gamma \frac{1}{M}\sum_{m=1}^{M} e_m^k$

$\hat{x}_{k+1} = x_{k+1} - \gamma e^{k+1} = x_k - \gamma g^k - \gamma e^k - \gamma \nabla f(x_k) + \gamma g^k$

$\hat{x}_k$

$\Rightarrow \hat{x}_{k+1} = \hat{x}_k - \gamma \nabla f(x_k)$

Decent на $\hat{x}_k$, $\|e_k\|^2$, сходимость до $\|e^0\| = 0$

Koloskova 2020 (nonconvex)

$O\left(\frac{L(f(x^0) - f^*)}{\varepsilon^2}\right)$ dim.

Beznosikov 2021 μ-sc

$O\left(\frac{L}{\mu}\log\frac{\varphi^0}{\varepsilon} + \frac{\sigma_*^2}{\mu\varepsilon}\right)$

2021 zog (Richtarik)

EF + Diana = EF21

Diana + $\alpha = 1$ = EF21

— Тупо EF21 — Nonconvex.

— PAGE (2021, Richtarik)

1) $f(x_{k+1}) \le f(x_k) - \frac{\gamma}{2}\|\nabla f(x_k)\|^2 - \left(\frac{1}{2\eta} - \frac{L}{2}\right)\|x_{k+1} - x_k\|^2 + \frac{\gamma}{2}\|g^k - \nabla f(x_k)\|^2$

2) Дисперсия на $\sigma_{k+1}^2 \le (1-\lambda)\,\sigma_k^2$

$\Rightarrow$ Итого: $\tilde{O}\left(\frac{LA}{\varepsilon^2}\right)$

↑ улучшенная оценка

EF-BV: (Condat, 2022)

$$\mathbb{E}\left[\|C(x) - x\|^2\right] = \underbrace{\mathbb{E}\left[\|C(x) - \mathbb{E}C(x)\|^2\right]}_{\text{variance}} + \underbrace{\|\mathbb{E}C(x) - x\|^2}_{\text{bias}}$$

класс $\begin{cases} \|\mathbb{E}C(x) - x\| \le \eta\,\|x\| \\ \mathbb{E}\left[\|C(x) - \mathbb{E}C(x)\|^2\right] \le w\,\|x\|^2 \end{cases}$ строго больше $\mathcal{U}$ и $\mathcal{B}$.
