Занятие 8. Локальные шаги + ?

$$\min_{x \in \mathbb{R}^d} f(x) = \frac{1}{M} \sum_{m=1}^{M} f_m(x)$$

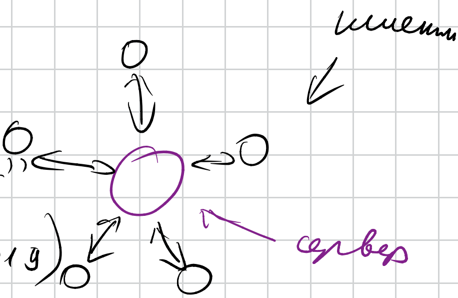

"Tighter theory..."

Local GD (Khaled 2019)

$k = 0, \dots, K-1$ (K − кол-во локальных эпох)

рассылка

$\forall m = \overline{1, M}$: $x^k_{m,0} = x^k$

усреднение точки по устр.

$$\begin{cases} l = 0, \dots, H-1 & (H \text{ − количество локальных шагов в эпохе}) \\ x^k_{m,l+1} = x^k_{m,l} - \gamma \nabla f_m(x^k_{m,l}) \end{cases}$$

GD

конец эпохи

$\to x^{k+1}_m = \underline{x^k_{m,H}}$ → отправляю на сервер.

Сервер: $x^{k+1} = \frac{1}{M} \sum_{m=1}^{M} x^{k+1}_m$ (точку)

$T = KH$

$$f(\tilde{x}_T) - f(x^*) = O\left(\frac{R_0^2}{\gamma T} + \frac{\gamma \sigma^2_{dif}}{M} + \gamma^2 L (H-1)^2 \sigma^2_{dif} \right)$$

$$\sigma^2_{dif} = \frac{1}{M} \sum_{m=1}^{M} \|\nabla f_m(x^*)\|^2$$

оно уже возникало

1) Локальные шаги − same as QGD ($H = 1$)

2) Это оптимальный результат.

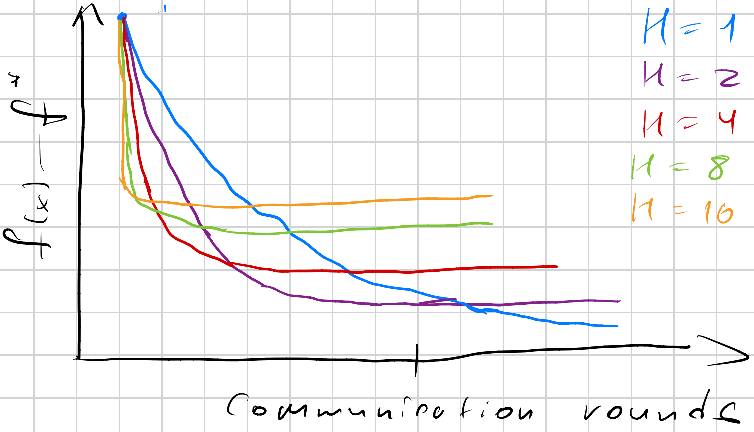

Local GD

M = 2, H = 3

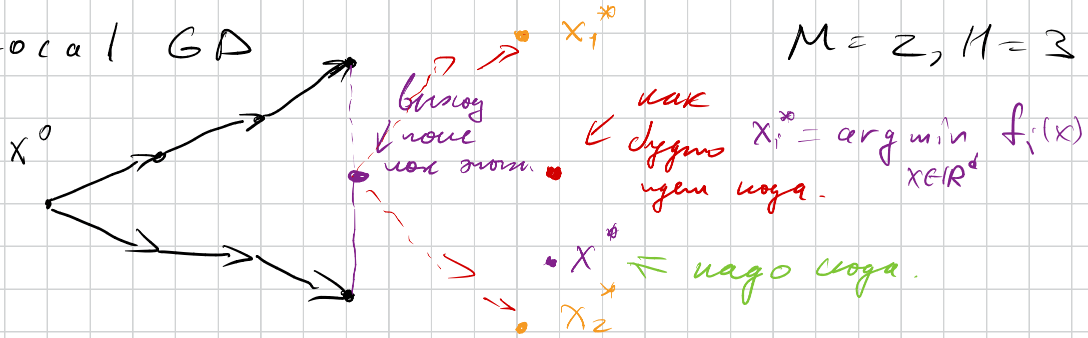

$x_i^* = \arg\min_{x \in \mathbb{R}^d} f_i(x)$

SCAFFOLD (2019)

1 шаг

$$x^k_{m,0} = x^k$$

$$\begin{cases} l = 0, \dots, H-1: \\ x^k_{m,l+1} = x^k_{m,l} - \gamma\left(\nabla f_m(x^k_{m,l}) - c_m + c\right) \end{cases}$$

Local control variate.

global control variate

не совсем так!

shift.

$$c_m^+ = c_m - c + \frac{1}{H\gamma}\left(x^k - x^k_{m,H}\right)$$

Вышлю: $(x^k_{m,H} - x^k, \; c_m^+ - c_m)$ → серверу.

$$c_m = c_m^+$$

$$x^{k+1}_m = x^k_{m,H}, \quad c := c + \frac{1}{M}\sum_{m=1}^{M}(c_m^+ - c_m)$$

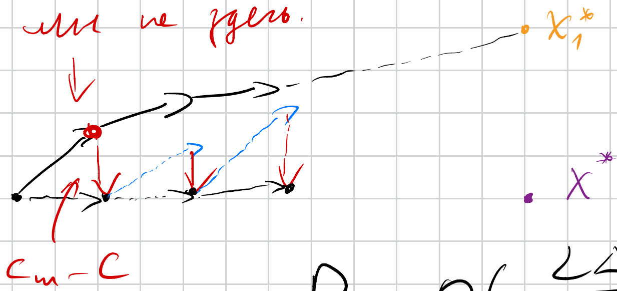

$$R = O\left(\frac{L\Delta}{\varepsilon^2}\right)$$ для невыпуклого случая.

$\uparrow$

количество коммуникационных раундов.

Вопрос закрыт!

Вопрос и замечание: сходимость должна "ускоряться" при росте похожести данных в плане времени.

$$f(x) = \frac{1}{M}\sum_{m=1}^{M} \frac{1}{N}\sum_{n=1}^{N} L(x, z_m^n)$$

$$D_1 = D_2 = \ldots = D_M \text{ (распр. данных)}$$

$$\mathbb{E}_{z_m^n}\left[\nabla^2 L(x, z_m^n) - \nabla^2 f(x)\right] = 0$$

Th (Хефдинг)

$\exists \{X_j\}_{j=1}^{N}$ — независимые симметричные с.м.

1) $\mathbb{E}[X_j] = 0$

2) $X_j^2 \preceq A_j^2$, $A_j \in S^d$

$$\mathbb{P}\left\{ \left\| \sum_{j=1}^{N} X_j \right\|_F \le t \right\} \ge 1 - d\exp\left(-\frac{t^2}{8\sigma^2}\right),$$

$$\sigma^2 = \left\| \sum_{j=1}^{N} A_j^2 \right\|_F \quad \checkmark \qquad \ge 1 - p$$

$$t \le \sqrt{8\sigma^2 \ln\left(\frac{d}{p}\right)}$$

1) $\nabla^2 L(x, \cdot) \preceq L I_d$

$$X_m^u = \underline{\frac{1}{N}}\left[\underline{\nabla^2 L(x, z_m^u) - \nabla^2 f(x)} \right]$$

$$\mathbb{E}_{z_m^u \sim D}\left[X_m^u\right] = 0$$

$$\left(X_m^u\right)^2 \preceq \frac{4L^2}{N^2} I_d = A$$

$$t \le \sqrt{C \frac{L^2}{N} \ln\left\{\frac{d}{p}\right\}} \simeq \log(\ldots) \cdot \frac{L}{\sqrt{N}}$$

превращ. в предп. →

data - identical: $\|\nabla^2 f_i(x) - \nabla^2 f(x)\| \le \delta \sim \frac{L}{\sqrt{N}}$

Лучшая оценка для SCAFFOLD:

корни (weak convexity)

$$R = O\left(\frac{(\sqrt{L\delta} + \rho)\Delta}{\varepsilon^2}\right)$$

(Luo, Stich, Horváth, Takáč)

2025

Хотим: $O\left(\frac{\delta\Delta}{\varepsilon^2}\right)$???

$\delta \sim \frac{L}{\sqrt{N}}$, $\sqrt{L\delta} \sim \frac{L}{N^{1/4}}$

А дальше то что?

$$\boxed{\|\nabla^2 f_1 - \nabla^2 f\| \le \delta}$$

данные могут быть гетерогенными, но Сервер о них знает!

$$\nabla^2 f_1(x) \preceq \overset{\Downarrow}{\delta} I_d + \nabla^2 f(x) + \nabla^2 f(x) \preceq \nabla^2 \psi(x)$$

2) μ-sc! $\nabla^2 f(x) \succeq \mu I_d \;\Big|\cdot \frac{2\delta}{\mu}$

$$\frac{2\delta}{\mu}\nabla^2 f(x) - \delta I_d \succeq \delta I_d \succeq \nabla^2 f_1(x) - \nabla^2 f(x)$$

$\mu\nabla^2\psi(x)$

$$\left(1 + \frac{2\delta}{\mu}\right)\nabla^2 f(x) \succeq \underbrace{\nabla^2 f_1(x) + \delta I_d}$$

$\left[\psi(x) = f_1(x) + \frac{\delta}{2}\|x\|_2^2\right]$

$$\nabla^2\psi(x) \succeq \nabla^2 f(x) \succeq \left(1 + \frac{2\delta}{\mu}\right)^{-1}\nabla^2\psi(x)$$

[Mirror Descent.

$$x_{k+1} = \arg\min_x \left\{ \gamma\langle \nabla f(x_k), x \overset{-x^k}{} \rangle + D_\psi(x, x_k) \right\}$$

дивергенция Брегмана.]

GD: $x_{k+1} = x_k - \gamma\nabla f(x_k)$

Mirror Descent в адекватной форме.

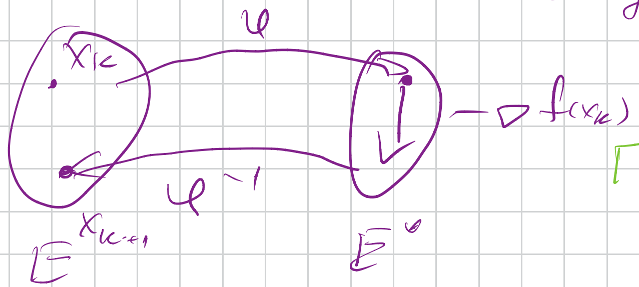

$$\boxed{\varphi = \nabla\psi}$$

$$\varphi(x_{k+1}) = \varphi(x_k) - \gamma\nabla f(x_k)$$

$$D_\psi(x,y) = \psi(x) - \psi(y) - \langle \nabla\psi(y), x-y \rangle$$

$$O\left(\frac{L_\psi}{\mu_\psi}\log\frac{1}{\varepsilon}\right) = O\left(\frac{\delta}{\mu}\log\frac{1}{\varepsilon}\right) =$$

$$\simeq O\left(\frac{L}{\sqrt{N}\mu}\log\frac{1}{\varepsilon}\right)$$

$$?\; x^{k+1} \overset{\text{local steps}}{\approx} \operatorname*{arg\,min}_x \Big\{ \overbrace{\langle \underbrace{\nabla(f-f_1)}_{\nabla f_2,\ \nabla f_3, \ldots,\ \nabla f_m}(x^k), x-x^k \rangle + \frac{1}{2\theta}\|x-x^k\|_2^2 + f_1(x)}^{A^k(x)} \Big\} \;?$$

(Вернулись к локальным) (шагам – ?)

(*)

1-ое устройство играет роль сервера.

Имею право решать с точностью

$$\|\nabla A^k(x^{k+1})\|^2 \le \frac{\delta^2}{3}\|x^k - \operatorname*{arg\,min}_x A^k(x)\|^2$$

История:

1) 2014 год: DANE $O\left(\frac{\delta^2}{\mu^2}\log\frac{1}{\varepsilon}\right)$

2) 2024 год: S-DANE $O\left(\frac{\delta}{\mu}\log\frac{1}{\varepsilon}\right)$

3) Проблема ускорения.

- $$f(x) = (f - f_1)(x) + f_1(x) \approx$$
$$\approx \left((f-f_1)(x^k) + \langle \nabla(f-f_1)(x^k), x - x^k\rangle + \frac{1}{2\theta}\|x-x^k\|^2 + f_1(x)\right)$$

На каждой итерации аппроксимацию.

$f - f_1$ — дорого!

- f_1 — дешево. параллель с доступностью оракулов =>

=> композитная задача.

$$x^{k+1} = \mathrm{prox}_{\theta f_1}\left(x^k - \theta\nabla(f-f_1)(x^k)\right) \quad (*)$$

Lan (2016) — Accelerated gradient sliding

$f(x) = r(x) + q(x)$ — convex + convex.

Kovalev (2022) nonconvex + convex

Accelerated Extragradient.

- $x_g^k = \tau x^k + (1-\tau)x_f^k$

- $x_f^{k+1} \approx \arg\min_x \{ \langle \nabla(f - f_1)(x_g^k), x - x_g^k \rangle +$
  $+ \frac{1}{2\theta}\|x - x_g^k\|^2 + f_1(x) \}$

как?

- $x^{k+1} = x^k - \eta\alpha(x_f^{k+1} - x^k) - \underline{\eta \nabla f(x_f^{k+1})}$

$$\left(\quad R = \tilde{O}\left(\sqrt{\frac{\delta}{\mu}} \log\frac{1}{\varepsilon}\right) - \right.$$

коммун. раунды

Использование компрессии убийственно!

Из-за VR

2025 год. (Bylinkin, Beznosikov)

Если я пытаюсь помешать Compression и Local steps => [SVRG, KatyushaX + similarity.]

$$O\left(\boxed{B}^{1/4}\sqrt{\frac{\delta}{\mu}} \log\frac{1}{\varepsilon}\right)$$

битов (кардинации)